Segmentasi Produk–Outlet untuk Perencanaan Stok

Laporan Quiz Machine Learning · Clustering Pola Permintaan

Data transaksi kasir 3 outlet kedai kopi, Jan–Sep 2025

1. Latar Belakang dan Tujuan

Kedai kopi punya 94 produk di 3 outlet. Menyimpan semua produk dalam jumlah sama di tiap outlet membuat stok menumpuk di produk sepi dan kosong di produk laris. Laporan ini mengelompokkan **produk di tiap outlet** berdasarkan pola permintaan, lalu menandai produk yang perlu perlakuan khusus.

Pertanyaan: (1) ada berapa tipe pola permintaan? (2) produk mana yang masuk tipe mana? (3) algoritma & ukuran jarak mana yang paling masuk akal? (4) produk mana yang polanya tidak biasa (noise)?

2. Data dan Metode

Sumber: `Transactions.csv`, 53.820 struk dari 3 outlet (SHOP001–003), 272 hari.

Alur pengolahan:

1. **Bersih.** Hapus struk duplikat, pecah struk multi-item (`"A, B"`) → 61.973 item terjual.
2. **Deret harian.** Hari tanpa penjualan dicatat 0 (bukan dihilangkan) agar rata-rata permintaan tidak terlalu tinggi.
3. **Fitur.** Dari deret harian dihitung 9 fitur perilaku per produk×outlet: `mean_daily` (rata-rata harian), `cv` (kestabilan), `zero_day_ratio` (rasio hari kosong), `max_daily`, `trend_weekly_pct`, `weekend_ratio`, `momentum_30d`, `share_morning`/`share_evening` (porsi jam ramai), `loyalty_share`, `avg_price`.
4. **Saring.** Fitur yang hampir kembar (|korelasi| ≥ 0.90) dibuang agar tidak dihitung ganda.
5. **Skala.** Log-transform untuk fitur sangat miring, lalu Z-score agar semua fitur setara.

Hasil akhir: matriks **282 baris** (produk×outlet) × **9 fitur** siap diklaster.

3. Temuan Eksplorasi (EDA)

- Total pendapatan Rp 1,315 miliar dari 53.820 transaksi; rata-rata transaksi berbayar Rp 25.252.
- 1.733 transaksi (3,2%) bernilai Rp 0 dan **100%**-nya memakai kartu loyalitas → penukaran reward, bukan data rusak.
- SHOP001 outlet tersibuk, disusul SHOP003 lalu SHOP002.
- Pembayaran didominasi BCA, jauh di atas Cash dan GoFood.
- 86% transaksi hanya berisi 1 item → peluang **bundling/upselling**.
- Pola jam sibuk terlihat jelas; berguna untuk jadwal staf dan penambahan stok harian.

4. Hasil Clustering

Tujuh model diuji: K-Means (3 jarak) dan DBSCAN (3 jarak) plus HDBSCAN. `Silhouette (Euclid)` dipakai sebagai pembanding yang adil karena dihitung di ruang jarak yang sama untuk semua model.

Model	Parameter	Klaster	Noise	Silh. (Eucl)	Davies-Bouldin	Cakupan
HDBSCAN	min_size=5	4	45,7%	**0,217**	1,418	54,3%
KMeans-cosine	k=3	3	0%	0,203	1,810	100%
KMeans-manhattan	k=3	3	0%	0,199	1,830	100%
KMeans-euclidean	k=4	4	0%	0,195	**1,658**	100%
DBSCAN-manhattan	eps=4,0	2	22,0%	0,182	0,985	78,0%
DBSCAN-euclidean	eps=2,0	2	14,5%	0,158	1,020	85,5%
DBSCAN-cosine	eps=0,2	3	9,2%	0,036	1,780	90,8%

Cara membaca. Silhouette tinggi = klaster rapat dan terpisah; Davies-Bouldin rendah = klaster kompak. HDBSCAN punya Silhouette tertinggi tetapi hanya menilai 54% data — sisanya 45,7% dibuang sebagai noise. Jadi skornya tinggi karena cakupan sempit, bukan karena lebih baik secara keseluruhan. DBSCAN-cosine skornya sangat rendah karena jarak cosine menghasilkan klaster yang tumpang tindih pada data ini.

5. Perbandingan dan Kesepakatan Antar Model

Selain metrik, dihitung **Adjusted Rand Index (ARI)** — seberapa mirip dua model membagi data (1 = identik, 0 = acak).

- Paling sepakat: **KMeans-cosine vs KMeans-manhattan (ARI 0,88)** → ketiga K-Means pada dasarnya menemukan pembagian yang sama; pilihan jarak tidak mengubah cerita besar.
- DBSCAN-euclidean vs DBSCAN-manhattan (0,61) juga cukup sepakat.
- Paling berbeda: **HDBSCAN vs DBSCAN-euclidean (−0,04)** → wajar, karena HDBSCAN membuang 45,7% data sebagai noise sedangkan DBSCAN-euclidean hanya 14,5%.

Pilihan model: K-Means-euclidean ($k=4$) dipakai sebagai model utama karena mencakup 100% data, jumlah klaster seimbang (67/93/63/59), dan Davies-Bouldin terendah di antara K-Means. DBSCAN/HDBSCAN tetap berguna sebagai **pendeteksi noise**, bukan pengganti segmentasi utama.

6. Interpretasi Klaster (K-Means Euclidean)

Klaster	mean_daily	zero_day	cv	Nama
0 (67)	0,74	0,48	1,17	Permintaan sedang, sore ramai
1 (93)	1,18	0,31	0,93	Fast mover, stabil
2 (63)	0,50	0,61	1,45	Slow mover, sering kosong
3 (59)	0,62	0,55	1,31	Slow mover, harga murah

Artinya untuk stok: klaster 1 (mis. BLACK Houseblend, Hazelnut Latte) harus selalu tersedia — permintaannya tinggi dan stabil. Klaster 2 dan 3 (mis. Creamy Klepon, Air Mineral, Lemons) sebaiknya distok sedikit dan dipantau, karena sering tidak terjual dan permintaannya naik-turun.

7. Kesimpulan dan Limitasi

Kesimpulan. (1) Pola permintaan terbagi menjadi 4 tipe yang jelas dan bisa dinamai. (2) K-Means memberi cakupan penuh, HDBSCAN/DBSCAN menandai produk berpola tidak biasa. (3) Produk **fast mover** layak diprioritaskan stoknya, **slow mover** dikurangi porsinya.

Limitasi. Hanya 282 sampel (produk×outlet) dan sembilan bulan data; musiman tahunan belum terlihat. PCA hanya dipakai untuk gambar, bukan untuk clustering. Nilai Silhouette semua model tergolong rendah (< 0,4), jadi segmentasi ini lebih cocok sebagai **panduan prioritas stok**, bukan aturan mutlak.

Langkah lanjut: uji data tahun kedua, tambah fitur musiman/promo, dan evaluasi ulang model terbaik.